Centro de investigación y estudios avanzados del IPN
Departamento de Computación

Protocolo de tesis

Tesista: Edgar Tobón Sosa
Director de tesis: [Grado y nombre del director], [Grado y nombre del codirector].

29 de octubre de 2026

Resumen

Las imágenes hiperespectrales (HSI) registran cientos de bandas espectrales por píxel, lo que permite distinguir materiales que en una fotografía convencional resultan indistinguibles; sin embargo, su clasificación mediante aprendizaje profundo exige un alto volumen de datos etiquetados, y etiquetar píxeles es costoso. Para enfrentar esta limitación se emplean las redes convolucionales de grafos (GCN) con aprendizaje semi-supervisado, las cuales operan sobre un grafo cuyos nodos son superpíxeles, por lo que la calidad de la segmentación determina el resultado de la clasificación. Un trabajo previo mostró que ningún algoritmo de segmentación resulta superior en todas las escenas y que la varianza explicada (EV), que mide cuánta información espectral se conserva dentro de un superpíxel, predice la exactitud de clasificación mejor que su pureza geométrica. No obstante, los algoritmos actuales forman los superpíxeles mediante reglas fijas que no optimizan la EV y que, al tomar decisiones discretas, impiden el uso del gradiente. Se propone el desarrollo de un segmentador diferenciable basado en Superpixel Sampling Networks (SSN) que, mediante entrenamiento no supervisado, realice la segmentación buscando maximizar la EV sin descuidar la compacidad de los superpíxeles. El método se evaluará sobre seis conjuntos de datos de referencia con cinco muestras etiquetadas por clase, frente a SLIC y PCNN-SAM, y se espera que logre una exactitud de clasificación igual o superior en escenas de dificultad tanto geométrica como espectral.

Palabras clave: imágenes hiperespectrales, superpíxeles diferenciables, redes convolucionales de grafos, aprendizaje semi-supervisado, varianza explicada, aprendizaje no supervisado.

1. Datos Generales

1.1. Título de proyecto

Superpíxeles diferenciables guiados por retención espectral para la clasificación semi-supervisada de imágenes hiperespectrales mediante redes convolucionales de grafos

1.2. Datos del alumno

Nombre:	Edgar Tobón Sosa
Matrícula:	251270014
Dirección:	Calle Necaxa 140, Int 8. Col. Portales Norte C.P. 03300 Ciudad de México, CDMX.
Teléfono (casa):	2225081400
Teléfono (lugar de trabajo):	
Dirección electrónica:	etobon96@gmail.com
Portal Internet:	

1.3. Institución

Nombre:	CINVESTAV-IPN
Departamento:	Depto. de Computación.
Dirección:	Av. Instituto Politécnico Nacional No. 2508, Col. San Pedro Zacatenco, México, D. F. 07300.
Teléfono:	(52) (55) 5747 3758

1.4. Beca de tesis

Institución otorgante:
Tipo de beca:
Vigencia:

1.5. Proyecto de origen[1]

Institución:
Nombre del proyecto:
Fuente de financiamiento:

1.6. Datos del asesor

Nombre:	Xiaoou Li Zhang
Dirección:	Av. Instituto Politécnico Nacional No. 2508, Col. San Pedro Zacatenco, México, D.F. 07300
Teléfono (oficina):	
Institución:	CINVESTAV-IPN
Departamento adscripción:	Departamento de Computación
Grado académico:	

1.7. Datos del coasesor

Nombre:	
Dirección:	Av. Instituto Politécnico Nacional No. 2508, Col. San Pedro Zacatenco, México, D.F. 07300
Teléfono (oficina):	
Institución:	CINVESTAV-IPN
Departamento adscripción:	Departamento de Computación
Grado académico:	

2. Descripción del proyecto

2.1. Resumen

En el presente trabajo se busca la respuesta a la pregunta: ¿[pregunta de investigación]?

[Describir qué se va a proponer, para quién y cómo se espera responder a la pregunta.]

2.2. Antecedentes y motivación para el proyecto

[Redactar antecedentes y motivación. Ejemplo de cita: una arquitectura de referencia se describe conforme a [**?**].]

3. Planteamiento del problema

Las imágenes hiperespectrales (HSI) registran cientos de bandas espectrales por píxel, lo que permite distinguir materiales que en una fotografía convencional resultan indistinguibles [REF]. Las arquitecturas neuronales con aprendizaje profundo para la clasificación de HSI son utilizadas en la caracterización de superficies terrestres, como lo son: (lista de aplicaciones) [REF]. Sin embargo, estas arquitecturas exigen un alto volumen de datos etiquetados, y etiquetar píxeles es costoso, por lo que en la práctica se dispone de muy pocas muestras [REF]. Para enfrentar esta limitación se emplean, entre otras, las redes convolucionales de grafos (GCN) con aprendizaje semi-supervisado [REF]. Mediante algoritmos de segmentación (lista de algoritmos) [REF], los píxeles se agrupan en superpíxeles, con los cuales se genera un grafo donde los nodos son superpíxeles unidos por aristas entre regiones vecinas. Este grafo es el que utiliza la GCN para propagar la información de los pocos nodos etiquetados hacia el resto. Los algoritmos tradicionales de segmentación fueron diseñados para imágenes de baja dimensionalidad, por lo que, para aplicarlos a HSI, es necesario reducir la dimensionalidad mediante PCA [REF]. Esta reducción suaviza las diferencias espectrales sutiles entre clases parecidas, lo que aumenta el riesgo de que dos clases distintas se mezclen en un mismo superpíxel, disminuyendo así la calidad de los nodos del grafo. El éxito de las GCN depende de la calidad del grafo base, ya que los errores de segmentación se heredan al grafo: todos los píxeles de un nodo mezclado reciben una misma etiqueta, y su firma espectral mezclada se propaga hacia sus vecinos. Con tan pocas etiquetas, la GCN no cuenta con evidencia suficiente para corregir estos errores (Galarza, 2026).

Galarza (2026) propuso el algoritmo PCNN-SAM, que suprime la etapa de PCA y forma los

superpíxeles a partir del vector espectral completo de la HSI. Su evaluación mostró que ningún algoritmo de segmentación resulta superior en todas las escenas: los métodos tradicionales, en particular SLIC, dominan en escenas con bordes geométricos bien definidos, mientras que PCNN-SAM obtiene su mayor ventaja en escenas con clases espectralmente parecidas. Asimismo, concluyó que la varianza explicada (EV), que mide cuánta información espectral se conserva dentro de un superpíxel, predice la exactitud de clasificación casi el doble de bien que la exactitud de segmentación alcanzable (ASA), que mide su pureza geométrica.

Sin embargo, tanto los algoritmos tradicionales como PCNN-SAM forman los superpíxeles mediante reglas fijas diseñadas a mano, que favorecen la EV de forma indirecta, pero no la optimizan; de hecho, PCNN-SAM no obtiene la EV más alta en cinco de los seis conjuntos de datos evaluados (Galarza, 2026). Además, estas reglas toman decisiones discretas (un píxel pertenece o no a una región), lo cual impide realizar una segmentación que busque maximizar la EV con el uso del gradiente.

Se propone el desarrollo de un modelo basado en Superpixel Sampling Networks (SSN) [REF] que, mediante entrenamiento no supervisado, realice la segmentación de la HSI buscando maximizar la EV, sin descuidar la compacidad de los superpíxeles. Con ello se busca responder la siguiente pregunta de investigación: logra una exactitud de clasificación semi-supervisada igual o superior a la de SLIC y PCNN-SAM, tanto en escenas de dificultad geométrica como espectral?

4. Objetivos generales y particulares del proyecto

4.1. General

Desarrollar un segmentador en superpíxeles diferenciable, basado en Superpixel Sampling Networks (SSN) con afinidad espectral angular y entrenado sin etiquetas para maximizar la varianza explicada (EV) con una restricción de compacidad, y evaluar su efecto en la clasificación semi-supervisada de imágenes hiperespectrales mediante redes convolucionales de grafos (GCN), en escenas de dificultad geométrica y espectral.

4.2. Particulares

I Reproducir la arquitectura PCNN-GCN de Galarza (2026) y los métodos de referencia (SLIC, LSC, ERS, SEEDS y PCNN-SAM) sobre seis conjuntos de datos hiperespectrales, con el protocolo de cinco muestras etiquetadas por clase, para establecer la línea base de comparación.

II Adaptar la arquitectura SSN a imágenes hiperespectrales mediante un extractor de características espectrales y una afinidad angular, inspirada en SAM, entre píxeles y superpíxeles.

III Formular una función de pérdida no supervisada que combine la EV, calculada sobre las bandas originales, con un término de compacidad espacial, y entrenar con ella el segmentador sin utilizar etiquetas.

IV Evaluar los superpíxeles obtenidos integrándolos en el clasificador GCN semi-supervisado y comparándolos con los métodos de referencia mediante métricas de segmentación (ASA, BR y EV) y de clasificación (OA, AA y κ).

V Analizar los resultados por tipo de escena (dificultad geométrica o espectral) y cuantificar la relación entre las métricas de segmentación y la exactitud de clasificación, para contrastar el hallazgo de Galarza (2026).

VI Determinar, mediante ablaciones, el efecto del peso de la compacidad (λ), de la dimensión de las características aprendidas y del cálculo de la afinidad sobre las bandas originales frente a las características aprendidas.

VII Explorar el entrenamiento de extremo a extremo del segmentador junto con la GCN, de modo que las muestras etiquetadas también influyan en la formación de los superpíxeles.

5. Metodología

La presente investigación se ha pensado llevar a cabo de la siguiente manera:

5.1. Redacción del protocolo de tesis para la aceptación del proyecto

5.2. Revisión del estado del arte y estudio de los fundamentos

- Estudio de los fundamentos de aprendizaje profundo: retropropagación, optimización y regularización, así como su implementación en PyTorch.
- Estudio de las redes neuronales de grafos y del modelo GCN de Kipf y Welling, y su implementación con PyTorch Geometric sobre conjuntos de datos de prueba.
- Estudio de la tesis de referencia sobre PCNN-SAM y PCNN-GCN, de los algoritmos de superpíxeles clásicos (SLIC) y de los métodos de superpíxeles diferenciables (Superpixel Sampling Networks y variantes).
- Revisión de los trabajos que acoplan superpíxeles y GCN en la clasificación de imágenes hiperespectrales, con énfasis en los que emplean matrices de asociación píxel-superpíxel.
- Elaboración de un cuadro comparativo de los trabajos relacionados.

5.3. Reproducción de las líneas base PCNN-GCN y SLIC-GCN

- Obtención y preparación de los conjuntos de datos hiperespectrales de referencia: Indian Pines, Salinas, Pavia University, WHU-Hi-LongKou, WHU-Hi-HanChuan y WHU-Hi-HongHu, con normalización min-max por banda.
- Integración del código de PCNN-SAM y del clasificador GCN de dos capas de la tesis de referencia, y de SLIC sobre la imagen reducida por PCA.
- Implementación del protocolo experimental: cinco superpíxeles etiquetados por clase, escala $K = 500$ y diez ejecuciones independientes con semillas fijas.
- Implementación de las métricas de segmentación (ASA, BR, EV) y de clasificación (OA, AA, κ).
- Verificación de que la OA obtenida difiera en no más de dos puntos porcentuales de la reportada en la tesis de referencia.

5.4. Diseño del módulo de superpíxeles diferenciable con afinidad espectral

- Implementación de un módulo inspirado en las Superpixel Sampling Networks, que extraiga características por píxel con una red convolucional ligera a partir del vector espectral completo.
- Definición de la asociación suave entre cada píxel y los superpíxeles de su vecindad (3×3 superpíxeles) mediante una afinidad angular basada en la similitud coseno, como equivalente diferenciable de SAM.
- Implementación de las iteraciones diferenciables de actualización de centros y asociaciones, restringidas a la vecindad local para mantener acotado el uso de memoria.
- Preentrenamiento del módulo sin etiquetas, con pérdidas de reconstrucción espectral y de compacidad, sobre cada escena.
- Comparación de los superpíxeles obtenidos frente a SLIC y PCNN-SAM mediante ASA, BR y EV, como verificación previa al acoplamiento con la GCN.

5.5. Construcción diferenciable del grafo de superpíxeles

- Cálculo de la matriz de características de los nodos como el promedio de las firmas espectrales ponderado por la asociación suave.
- Cálculo de la matriz de adyacencia a partir de la superposición de las asociaciones suaves entre superpíxeles vecinos, y su normalización simétrica.
- Proyección de las predicciones por superpíxel de regreso al nivel de píxel mediante la misma asociación suave.
- Verificación de que el gradiente de la pérdida de clasificación llegue al módulo de segmentación, mediante pruebas de gradiente sobre imágenes sintéticas pequeñas.

5.6. Definición de la función de pérdida y de la estrategia de entrenamiento

- Formulación de la pérdida compuesta: entropía cruzada sobre los nodos etiquetados, reconstrucción espectral (aproximación diferenciable de EV) y compacidad espacial.
- Definición de la estrategia de entrenamiento en dos fases: preentrenamiento no supervisado del módulo de segmentación y ajuste conjunto de extremo a extremo con la GCN.
- Ajuste de los pesos de cada término de la pérdida y de los hiperparámetros sobre un conjunto de validación, manteniendo la GCN de la tesis de referencia sin cambios para no introducir factores de confusión.
- Detección y corrección de soluciones degeneradas, como superpíxeles vacíos o asociaciones uniformes.

5.7. Evaluación comparativa de la arquitectura propuesta

- Ejecución de la arquitectura propuesta, PCNN-GCN y SLIC-GCN sobre los seis conjuntos de datos bajo el mismo protocolo (cinco muestras por clase, K = 500, diez ejecuciones).
- Medición de la calidad de segmentación (ASA, BR, EV), de clasificación (OA, AA, κ) y del costo computacional (tiempo de entrenamiento e inferencia, memoria).
- Estudio de ablación: superpíxeles aprendidos sin ajuste conjunto, sin pérdida de reconstrucción, sin término de compacidad y con distancia euclidiana en lugar de afinidad angular.
- Pruebas de significancia estadística entre métodos sobre las diez ejecuciones.

5.8. Análisis de la relación entre segmentación y clasificación

- Cálculo de la correlación de Pearson entre ASA, BR y EV y la OA sobre los pares conjunto de datos $\times$ método, incluyendo la arquitectura propuesta.
- Contraste con el hallazgo de la tesis de referencia sobre EV como mejor predictor de la OA.
- Análisis de los resultados según el tipo de dificultad de la escena (geométrica o espectral) y análisis visual de los mapas de clasificación.
- Presentación de resultados.

6. Cronograma de actividades (plan de trabajo)

	oct	nov	dic	ene	feb	mar	abr	may	jun	jul	ago
Revisión del estado del arte.	■	■	■	■	■	■	▒	▒	▒	▒	
Estudio de fundamentos de aprendizaje profundo, redes de grafos y superpíxeles diferenciables.	■	■	■	■							
Redacción y entrega del protocolo de tesis.	■	■	◆								
Reproducir las líneas base SLIC-GCN y PCNN-GCN sobre seis conjuntos de datos bajo el protocolo de referencia.		■	■								
Reproducir SSN en imágenes RGB (BSDS500) y evaluar su viabilidad.				◆							
Adaptar SSN a imágenes hiperespectrales mediante un extractor espectral y una afinidad angular inspirada en SAM.					■						
Formular la función de pérdida no supervisada (EV + compacidad) y entrenar el segmentador sin etiquetas.					■	■					
Integrar los superpíxeles en la GCN semi-supervisada y realizar la evaluación preliminar.						◆					
Explorar el entrenamiento de extremo a extremo del segmentador con la GCN.							■	■			
Evaluar la arquitectura propuesta frente a SLIC, LSC, ERS, SEEDS y PCNN-SAM, incluyendo el estudio de ablación.								■			
Analizar los resultados por tipo de escena y la relación entre las métricas de segmentación y la exactitud de clasificación.									■		
Redacción del manuscrito de tesis.					■	■	■	■	■	■	■
Revisión final, preparación de artículo y defensa.										■	◆

▒ = actualización continua. ◆ = hito.

7. Infraestructura

La infraestructura mínima necesaria para el desarrollo del proyecto de tesis es:

Hardware [Equipo de cómputo]

Software [Herramientas, lenguajes, plataformas]

8. Estado del arte

8.1. Marco teórico

[Redactar el marco teórico.]

8.2. Trabajos relacionados

[Describir los trabajos relacionados.]

8.3. Cuadro comparativo de los trabajos relacionados

Tabla 1: Cuadro comparativo de los trabajos relacionados

Trabajo	Referencia	Multiesp.	IA img.	FHIR	DICOM	Trazab. IA	Offline
[Nombre]	[cita]						
[Nombre]	[cita]						

Multiesp. = Multiespecialidad; IA img. = Diagnóstico por imagen asistido por IA; Trazab. IA = Trazabilidad del modelo de IA por anotación; Offline = Operación ante fallas de red; No esp. = No especifica.

9. Contribuciones o resultados esperados

Con este trabajo se espera obtener [resultado principal].

La arquitectura resultante de esta investigación va a cumplir con las siguientes características:

- [Característica]
- [Característica]

10. Referencias