Centro de investigación y estudios avanzados del IPN
Departamento de Computación

Veredicto de originalidad

Tesista: Edgar Tobón Sosa

10 de noviembre de 2026

1. Comparación con los trabajos más cercanos

Se revisaron los cinco trabajos que más se acercan a la propuesta: tres que aprenden superpíxeles dentro de una red de clasificación con GCN (Zhang et al. 2022; Li et al. 2023; Wang et al. 2025) y dos que forman superpíxeles para el agrupamiento no supervisado (Li et al. 2026; Cui et al. 2024). La Tabla 1 resume, para cada uno, cómo forma los superpíxeles, con qué señal los ajusta y si evalúa la calidad de la segmentación.

Tabla 1: Comparación de la propuesta con los trabajos más cercanos

Trabajo	Tarea	Superp.	Señal para formarlos	Asignación	Etiquetas	ASA/BR/EV
EMS-GCN (Zhang et al. 2022)	Clas. (GCN)	A (SSN)	EC + recons. de etiquetas + compacidad espacial (Ecs. 15–17 y 20)	Euclidiana^2 con posición (Ec. 1)	30 por clase; de 5 a 30 (Fig. 13)	No
FG-DGCN (Li et al. 2023)	Clas. (GCN)	A (SSN)	EC + recons. de etiquetas (Ecs. 16–17)	Euclidiana sin posición (Ec. 9)	200 por clase; 5 % (GT)	No
MSGTN (Wang et al. 2025)	Clas. (GCN + trans-former)	A (SSN, multi-escala)	Solo EC (Sec. IV-C)	Euclidiana^2 (Ec. 5)	1–5 % por clase	No
Li et al. (2026)	Agrup.	A (SSN)	Sin etiquetas: autorrepresentación + compacidad espectral + consistencia local (Ecs. 5, 15 y 16)	Euclidiana^2 con posición (Ec. 2)	0	No
S^{2}DL (Cui et al. 2024)	Agrup.	F (ERS sobre PCA)	No aplica	No aplica	0	No

Trabajo	Tarea	Superp.	Señal para formarlos	Asignación	Etiquetas	ASA/BR/EV
Propuesta	Clas. (GCN)	A (SSN)	Sin etiquetas: EV explícita + compacidad	Angular (tipo SAM)	5 por clase	Sí

Clas. = clasificación semisupervisada; Agrup. = agrupamiento no supervisado; Superp. = superpíxeles; A = aprendidos; F = fijos; EC = entropía cruzada; recons. = reconstrucción; ASA/BR/EV = reporta alguna métrica de calidad de la segmentación.

2. Veredicto

El hueco de investigación sigue abierto, pero es más estrecho de lo que plantea el protocolo. La afirmación de que los algoritmos actuales forman los superpíxeles mediante reglas fijas ya no es exacta: EMS-GCN, FG-DGCN y MSGTN los aprenden dentro de la red de clasificación, aunque los tres lo hacen con la señal de las etiquetas (Zhang et al. 2022; Li et al. 2023; Wang et al. 2025).

Tampoco puede afirmarse que la propuesta sea la primera en usar una pérdida espectral sin etiquetas. El término de compacidad espectral de Li et al. (2026), $\frac{1}{N}\sum_i \|X'_i - F_i\|^2$ (Ec. 5), es el error de reconstruir cada píxel con la media de su superpíxel, por lo que minimizarlo equivale a maximizar la EV. Sin embargo, ese trabajo lo emplea para el agrupamiento, como un término auxiliar y sin medir la EV. Además, entrenar los superpíxeles solo con ese término no mejoró el agrupamiento de forma consistente: en Salinas, la exactitud global bajó de 78.90 % a 77.86 % (variantes M1 y M2, Tabla III).

El mecanismo de reconstrucción tampoco es nuevo: EMS-GCN y FG-DGCN reconstruyen las etiquetas mediante $\tilde{Q}\hat{Q}^T Y$ (Zhang et al. 2022, Ec. 16; Li et al. 2023, Ec. 17); lo nuevo es reconstruir el espectro. Por último, el régimen de cinco etiquetas por clase no constituye una aportación por sí mismo, ya que EMS-GCN evalúa de 5 a 30 muestras por clase (Zhang et al. 2022, fig. 13).

2.1. Hueco de investigación reformulado

Los métodos que aprenden superpíxeles para clasificar imágenes hiperespectrales con GCN los ajustan con la señal de las etiquetas, y ninguno mide la calidad de la segmentación que produce (Zhang et al. 2022; Li et al. 2023; Wang et al. 2025). El único trabajo que los aprende con un término espectral sin etiquetas lo hace para el agrupamiento y sin evaluar el efecto de ese término por separado (Li et al. 2026). Por otra parte, Galarza (2026) encontró que la varianza explicada (EV) de los superpíxeles se relaciona con la exactitud de la clasificación semisupervisada mejor que la exactitud de segmentación alcanzable (ASA). Ningún trabajo usa la EV como criterio explícito y sin etiquetas para aprender los superpíxeles de una GCN semisupervisada, ni evalúa si maximizarla se traduce en una mayor exactitud cuando solo se dispone de cinco etiquetas por clase.

La originalidad de la propuesta se sostiene en tres puntos:

I La EV como criterio central y sin etiquetas para aprender los superpíxeles de una GCN semi-

supervisada, justificada por el hallazgo de Galarza (2026).

II La afinidad angular, inspirada en SAM, en la asignación diferenciable entre píxeles y superpíxeles; los trabajos revisados emplean la distancia euclidiana (Tabla 1).

III La evaluación de la segmentación aprendida mediante ASA, BR y EV, y de su relación con la exactitud de clasificación por tipo de escena, que ninguno de los trabajos revisados realiza.

Los propios autores de los trabajos revisados señalan esta dirección. Li et al. (2026) indican que los marcos de superpíxeles diferenciables se han aplicado principalmente a tareas supervisadas, en las que el gradiente proviene de las etiquetas (Sec. I); Wang et al. (2025) proponen como trabajo futuro reducir la dependencia de los datos etiquetados (Sec. VII), y Cui et al. (2024), desarrollar métodos de segmentación en superpíxeles diseñados específicamente para HSI (Sec. V).

2.2. Riesgo

La ablación de Li et al. (2026) sugiere que optimizar solo un término equivalente a la EV puede no mejorar la tarea final. Por ello, el diseño experimental debe admitir una respuesta negativa a la pregunta de investigación: los superpíxeles aprendidos se compararán contra SLIC y PCNN-SAM, y se medirá la relación entre la EV y la exactitud de clasificación.

3. Cambios en el protocolo

En el planteamiento del problema, la frase sobre las reglas fijas se sustituirá por el primer párrafo del hueco reformulado (Sección 2.1), se citará a Li et al. (2026) como el único antecedente con una señal espectral sin etiquetas y el riesgo de la Sección 2.2 se presentará como parte de la pregunta de investigación.

En los objetivos, los objetivos particulares II y III (afinidad angular y pérdida EV) se mantienen como el núcleo original; en el III se aclarará que la pérdida de reconstrucción proviene de SSN y que la aportación es reconstruir el espectro sin etiquetas. El objetivo V (relación entre las métricas de segmentación y la exactitud) se refuerza, porque ningún trabajo lo aborda con superpíxeles aprendidos. El objetivo VII (entrenamiento de extremo a extremo) se mantiene como exploratorio y se comparará con EMS-GCN, FG-DGCN y MSGTN, que ya siguen ese enfoque.

En el estado del arte, los trabajos relacionados incluirán un párrafo por cada uno de los cinco trabajos revisados, y la Tabla 1 servirá como base del cuadro comparativo.

4. Referencias

Cui, Kangning, Ruoning Li, Sam L Polk, et al. 2024. ≪Superpixel-Based and Spatially Regularized Diffusion Learning for Unsupervised Hyperspectral Image Clustering≫. *IEEE Transactions on Geoscience and Remote Sensing* 62: 1-18. https://doi.org/10.1109/tgrs.2024.3385202.

Li, Xianlu, Nicolas Nadisic, Shaoguang Huang, y Aleksandra Pižurica. 2026. ≪Joint Superpixel and Self-Representation Learning for Scalable Hyperspectral Image Clustering≫. *ICASSP 2026*

- *2026 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 546-50. https://doi.org/10.1109/icassp55912.2026.11464647.

Li, Zhongwei, Qiao Meng, Fangming Guo, et al. 2023. ≪Feature-guided dynamic graph convolutional network for wetland hyperspectral image classification≫. *International Journal of Applied Earth Observation and Geoinformation* 123: 103485. https://doi.org/10.1016/j.jag.2023.103485.

Wang, Tingting, Yao Sun, y Yunfeng Hu. 2025. ≪Multiscale Graph Transformer Network With Dynamic Superpixel Pyramid for Hyperspectral Image Classification≫. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 18: 13438-56. https://doi.org/10.1109/jstars.2025.3570267.

Zhang, Hongyan, Jiaqi Zou, y Liangpei Zhang. 2022. ≪EMS-GCN: An End-to-End Mixhop Superpixel-Based Graph Convolutional Network for Hyperspectral Image Classification≫. *IEEE Transactions on Geoscience and Remote Sensing* 60: 1-16. https://doi.org/10.1109/tgrs.2022.3163326.